AI Assignment 1 – Proje Raporu

Yağız Efe Çiçekçisoy · Foundations & Applications of AI · Ekim 2026

Bu ML eğitimi projesi için bir hafta süre ayırdım.
İlk başta uzun bir süre ML eğitim algoritmaları detaylıca kağıt kalem ile çalıştım/araştırdım. Arkalarındaki matematik ve mantıklarını anladım.
ML eğitmek için veri bulma - temizleme - keşifsel veri analizi - özellik mühendisliği - eğitim/test ayrımı - model seçimi - çapraz doğrulama ve hiperparametre ayarı - değerlendirme metrikleri - raporlama gibi pipeline'I araştırıp çalıştım.
Daha sonra AI Agent'lar ile birlikte eğitime başladım.
Burası önemli çünkü mühendislik kararlarını tamamen ben verdim. AI'a başlangıçta düştüğüm şerh, veri bilimindeki atılacak adımları, ve sonraki atılacak adımları yani kararları ben vereceğim, sen sadece labor'u yap dedim.

Bu aşamada gerçekten çok şey öğrendim.

Teslim öncesi AI Agent'ımdan geliştirme önerileri aldım. Projeyi daha profesyonel hale getirmek için önerileri inceleyip uygulamaya aldım:

SMS Spam (supervised):

- Sadece Naive Bayes vardı. Logistic Regression ve Linear SVM'i de ekleyip üçünü karşılaştırırsak hangi modelin bu veriye daha uygun olduğunu gösterebileceğimizi önerdi. Uyguladım, çapraz doğrulamada Linear SVM önde çıktı.
- Alpha için denediğim en iyi değer (0.1), aralığın en ucundaydı. Aralığı genişletirsek daha iyi bir değeri kaçırmadığımızdan emin olabileceğimizi önerdi. Genişlettim, yeni en iyi değer (0.01) aralığın içinde kaldı.
- Model her çalıştırmada yeniden eğitiliyordu. Kaydedersek tahmin için tekrar eğitmeye gerek kalmayacağını önerdi. Artık kaydediliyor.

Sonuçlar:

Önceki algoritma Multinomial Naive Bayes'ti. Kelimelerin spam ve normal mesajlarda ne sıklıkla geçtiğine bakarak olasılık hesaplıyor. Yeni algoritma Linear SVM. İki sınıfı birbirinden en geniş boşlukla ayıran sınırı arıyor.

Test verisi: 1.035 mesaj, içinde 131 spam.

Ölçüt	Anlamı	Önce (NB)	Şimdi (SVM)
Recall	Spamlerin kaçını yakaladık?	%63	%90
Precision	"Spam" dediklerimizin kaçı gerçekten spam?	%100	%95

Ölçüt	Anlamı	Önce (NB)	Şimdi (SVM)
F1	Recall ile precision'ın dengesi	0,77	0,925
Accuracy	Toplamda doğru tahmin oranı	%95,3	%98,2

- Eski model temkinliydi: hiç yanlış alarm vermiyordu ama 49 spamı kaçırıyordu.
- Yeni model sadece 13 spamı kaçırıyor. Karşılığında 6 normal mesaja yanlışlıkla spam diyor.
- Accuracy'ye fazla güvenmiyoruz: mesajların sadece %13'ü spam. Her mesaja "normal" diyen bir model bile %87 accuracy alır. Bu yüzden asıl ölçüt olarak F1'e bakıyoruz.

Futbolcu Piyasa Değeri (supervised):

- Log dönüşümünü sadece R^2'ye bakarak geri almıştım. Diğer ölçütlere de bakarsak log'un aslında tipik oyuncu için hatayı ciddi şekilde düşürdüğünü göreceğimizi önerdi. Kontrol ettim, haklıydı. Log dönüşümünü geri getirdim.
- Eksik değer doldurma ve one-hot encoding, eğitim/test ayrımından önce tüm veride yapılıyordu. Bu adımları pipeline'a taşırsak test verisinin eğitimi etkilemeyeceğini (veri sızıntısı olmayacağını) önerdi. Uyguladım.
- Tek bir model ve tek bir bölme vardı. Çapraz doğrulamayla birkaç modeli karşılaştırırsak seçimin şansa bağlı olmayacağını önerdi. Ridge, Random Forest ve Gradient Boosting'i karşılaştırdım, Gradient Boosting önde çıktı.
- Model sadece kariyer istatistiklerine bakıyordu, bu yüzden değeri düşmüş ya da verisi eksik oyuncularda çok yanılıyordu. Oyuncunun bir yıl önceki piyasa değerini ve sözleşmesinin bitmesine kalan süreyi eklersek bu hataların azalacağını önerdi. Üç sürümü (ek yok / sadece önceki değer / önceki değer + sözleşme) aynı test oyuncularında karşılaştırdım ve ikisini birlikte eklemeye karar verdim. Veri sızıntısı olmasın diye önceki değer olarak en az bir yıl önceki değerlemeyi kullandım.

Futbolcu Kümeleme (unsupervised):

- K=5'i elbow grafiğine göz kararı bakarak seçmiştim. Her K için silhouette skorunu hesaplarsak seçimi sayıyla gerekçelendirebileceğimi önerdi. Uyguladım, K=3 seçildi.

Sonuçlar:

Önceki algoritma Random Forest'tı. Birçok karar ağacı kurup tahminlerinin ortalamasını alıyor. Yeni algoritma Gradient Boosting. Ağaçları sırayla kuruyor, her yeni ağaç öncekilerin hatasını düzeltmeye çalışıyor.

Test verisi: 2.681 oyuncu. Üç sürüm de aynı oyuncularla test edildi.

Ölçüt	Anlamı	Önce (RF)	GB, ek özellik yok	Final (GB + önceki değer + sözleşme)
Medyan hata	Oyuncuların yarısında hata bundan küçük	636 bin €	372 bin €	235 bin €
±%50 içinde	Tahmini gerçeğe yeterince yakın olanların oranı	%40	%54	%71
2 kat+ yanlış	Çok kötü tahminlerin oranı	%47	%36	%18
MAE	Ortalama mutlak hata	2,12M €	1,92M €	1,37M €
R^2	Varyansın ne kadarı açıklanıyor?	0,70	0,67	0,83

- Basitçe: 10 oyuncudan ilk model 4'ünü, final model 7'sini gerçek değerin ±%50'si içinde tahmin ediyor.
- En büyük iyileşmeyi bir yıl önceki değer getirdi. Örneğin Szymański için tahmin 40M €'dan 19M €'ya indi (gerçek değeri 12M €), Camara için 2M €'dan 27M €'ya çıktı (gerçek değeri 20M €).
- En önemli özellikler bir yıl önceki değer, yaş ve lig çıktı.
- Model hâlâ bir yılda değeri birden yükselen genç yetenekleri yakalayamıyor (ör. Rodrigo Mendoza: gerçek 20M €, tahmin 8M €).

Kümeleme sonuçları (K=3, silhouette 0,33; eski K=5'te 0,21):

Küme	Oyuncu	Ort. yaş	Medyan değer
Genç / az deneyimli	9.946	26	0,7M €
Deneyimli, düzenli oynayan	3.140	32	1,4M €
Kariyerli yıldızlar, golcüler	319	33	3,5M €

- Kümeleme piyasa değerini hiç görmedi, ama gruplar değere göre sıralandı. Bu da kümelerin anlamlı olduğunu gösteriyor.

- Silhouette skoru 0,33 olduğu için kümeler çok net ayrışmıyor. Oyuncular kesin tiplerden çok, "az deneyimliden çok deneyimliye" uzanan bir çizgi üzerinde dağılıyor.